

多机理预训练实现稀疏工业数据下鲁棒的物理信息结垢预测

刘建成

浙江大学化学工程与生物工程学院，杭州 310058

希望投稿至 *Applied Thermal Engineering*

摘要

换热器结垢是过程工业中最大的能量损失来源之一，每年造成数十亿美元的经济损失。准确预测结垢热阻演化 $R_f(t)$ 是优化清洗周期的前提，但工业现场普遍面临监测数据严重不足的困境。本研究提出**多机理预训练 + 稀疏微调框架**：利用五种不同的结垢ODE模型预训练物理信息神经网络（PINN），随后在极少量的真实测量数据（ $N = 5-30$ 个点）上进行轻量微调。我们在从三篇同行评审论文中数字化提取的**18条真实结垢曲线**上验证了该框架，涵盖三种结垢类型（结晶结垢、原油结垢、 CaCO_3 沉淀结垢含诱导期），覆盖域内、域外和跨机理泛化场景。我们建立了关键的基线对比：直接用同一ODE模型对稀疏数据进行曲线拟合在18条曲线中的15条上失败（ $R^2 \approx 0$ 或负值），证实了纯物理模型在有限数据下不可靠。PINN 预训练弥合了这一缺口，在这15条失败案例中的12条上达到 $R^2 > 0.90$ 。核心发现包括：（1）多机理预训练至关重要，其价值在于**多样性而非覆盖面**——单机理（仅Kern-Seaton）预训练在自身目标曲线类型上灾难性过拟合， $R^2 = -1329$ ，而多机理预训练在同一曲线上达到 $R^2 = 0.94$ ；（2）在5-seed多seed验证中，PINN平均 R^2 在18条曲线中的12条上超过0.90；（3）预训练后的PINN 在外推任务中一致优于随机森林， $\Delta R^2 = +1.3$ 至 $+18.7$ （ $N = 5$ ）；（4）PINN驱动清洗策略相比固定周期策略将无量纲成本比降低20%–97%。该方法仅需公开可用的物理模型进行预训练，每台换热器的微调时间约3秒（消费级GPU）。

关键词：物理信息神经网络，换热器结垢，稀疏数据，迁移学习，清洗优化，多机理建模

1. 引言

1.1 结垢问题的工程背景

换热器是化工、石油、电力和食品加工行业的核心设备。运行过程中，溶解盐类（ CaCO_3 、 CaSO_4 ）、颗粒物和有机化合物在传热面上沉积，形成污垢层。污垢的导热系数（ $0.5\text{--}2\text{ W/m}\cdot\text{K}$ ）比金属管壁（ $50\text{--}400\text{ W/m}\cdot\text{K}$ ）低一到两个数量级。总热阻的增加迫使工厂要么增大传热温差（从而增加燃料消耗），要么接受产能下降。

结垢热阻 $R_f(t)$ 的演化由沉积与剥离两个竞争过程的净效应决定：

$$\frac{dR_f}{dt} = \phi_d - \phi_r$$

其中 ϕ_d 是沉积速率， ϕ_r 是剥离速率——两者均是局部温度、流速、浓度和表面条件的函数。

1.2 清洗决策问题

由于结垢不可避免，工业实践依赖定期清洗来恢复换热效率。清洗调度是一个优化问题：清洗太频繁会产生过高的停产成本；清洗间隔太长会导致能量损失不断累积。最优清洗周期使得“能量损失 + 清洗费用”之和最小。

这个优化需要准确预测 $R_f(t)$ ——特别是结垢热阻何时会超过临界阈值 $R_{f,\text{crit}}$ 。没有可靠的预测模型，清洗决策只能依赖启发式规则——通常是固定的日历周期。

1.3 数据稀缺问题

准确的 $R_f(t)$ 预测面临根本性障碍：工业结垢数据极度稀缺。工厂出于竞争敏感性不愿共享运营数据，安装专用结垢监测仪表成本高昂。典型的工业场景是仅有少量历史清洗记录和偶尔的温度/压力测量数据。

标准机器学习方法需要成百上千个标注样本才能达到可接受的精度。仅有5–30个数据点时——这就是真实的工业场景——纯数据驱动方法要么完全失败，要么产生物理上不合理的预测。

1.4 PINN作为解决方案及其局限性

物理信息神经网络（PINN）通过在标准数据损失函数中增加基于物理的正则化项来解决数据稀缺问题：

$$\mathcal{L} = \underbrace{\text{MSE}(R_f^{\text{pred}} - R_f^{\text{obs}})}_{\text{数据损失}} + \lambda \cdot \underbrace{\text{MSE}\left(\frac{dR_f}{dt} - (\phi_d - \phi_r), 0\right)}_{\text{物理损失}}$$

物理损失在不需要观测标签的配点上强制执行控制ODE，提供了无限的"免费"训练信号。

然而，现有的PINN结垢预测方法存在两个关键局限：（1）仅使用Kern-Seaton渐近模型作为物理约束，而真实结垢表现出多种机制——诱导期、阈值行为、清洗引起的不连续性；（2）所有实验都在合成数据上进行，造成自洽循环。

1.5 本研究的贡献

- 多机理ODE注册表**：实现了五种不同结垢ODE模型的统一接口
- 预训练 + 微调管线**：在180条曲线上多机理预训练的PINN可通过仅5–30个数据点的微调迁移到真实结垢曲线
- 全面的真实数据验证**：在18条真实曲线上验证，涵盖三种结垢类型
- 单机理 vs. 多机理消融**：证明了多机理多样性防止灾难性过拟合——这是预训练的核心机制
- ODE拟合基线及诚实评估**：直面方法的边界条件，坦诚承认纯ODE拟合在哪些场景更优

2. 方法论

2.1 多机理结垢ODE注册表

我们实现了五种结垢动力学模型：

模型1——Kern-Seaton（经典渐近型）：

$$\frac{dR_f}{dt} = A \exp\left(-\frac{E_a}{RT_w}\right) - B \cdot \tau_s \cdot R_f$$

$$R_f(t) = R_f^* (1 - \exp(-t/\tau))$$

适用于：结晶结垢、颗粒沉积结垢（渐近行为）。

模型2——Kern-Seaton带初始残余：适用于化学清洗后残余结垢的换热器。

模型3——简化KS（唯象型）：

$$\frac{dR_f}{dt} = \frac{R_f^* - R_f}{\tau}, \quad R_f(t) = R_{f0} + R_f^*(1 - e^{-t/\tau})$$

适用于所有参数未知的渐近型曲线。

模型4——诱导期 + 线性增长：

$$R_f(t) = \begin{cases} 0 & t < t_{\text{ind}} \\ k_{\text{growth}} \cdot (t - t_{\text{ind}}) & t \geq t_{\text{ind}} \end{cases}$$

解析形式在 $t = t_{\text{ind}}$ 处分段且不可微。对于PINN物理损失计算，我们使用sigmoid平滑近似（斜率 $\alpha = 10$ ）。

模型5——Ebert-Panchal阈值模型：包含不发生结垢的临界剪切应力条件。适用于原油结垢。

2.2 PINN架构

PINN采用统一的10维输入向量：

$$\mathbf{x} = [t, T_w, v, p_1, p_2, p_3, p_4, p_5, p_6, \text{ode_type_id}]^T$$

其中 p_1 – p_6 编码ODE特定物理参数，未使用的槽位填零。网络有4个隐藏层，每层64个神经元，tanh激活（13,249个参数）。物理损失使用注册表中适当的ODE残差函数按轨迹计算。

2.3 多机理合成数据预训练

预训练数据来自全部五种ODE模型，参数分层采样：域内（In-domain，匹配典型磷酸浓缩条件， $T_w = 340$ – 380 K， $v = 0.8$ – 2.5 m/s）、域外1（OOD-1，偏移参数范围）和域外2（OOD-2，完全不同的结垢机理）。每种ODE模型生成200条域内 + 100条域外1 + 100条域外2轨迹（每条60个时间点），共计2,000条轨迹。预训练运行3,000个epoch。

2.4 真实数据稀疏微调

对每条真实结垢曲线，微调流程为：（1）基于曲线视觉特征和来源文献报告的结垢类型选择匹配的ODE模型；（2）在稀疏点上用 `scipy.curve_fit` 拟合选定的ODE模型；（3）将估计参数编码为10维输入格式；（4）从预训练权重初始化，微调2,000个epoch；（5）在完整时间范围上评估。

2.5 基线方法与消融设计

四个基线：Random Forest（100棵树）、XGBoost（100轮）、MLP（64-32）、LSTM（单层）。消融变体：Main（PT+Phys）、A1（NoPT+Phys，无预训练+物理损失）、A2（PT+NoPhys，预训练+无物理微调）、A3（NoPT+NoPhys，纯NN从零训练）、KS-only PT（仅Kern-Seaton预训练）。

2.6 真实结垢曲线数据集

我们从三篇同行评审论文中数字化了18条真实 $R_f(t)$ 曲线：

来源	结垢类型	系统	曲线数	时间范围	R_f 范围
Jradi et al. (2018)	结晶 (磷酸)	管式换热器	1	0–102 h	1.7×10^{-6} – 1.6×10^{-4}
Benyahia et al. (2014)	原油	炼油厂E101	2	665–733 d	9.1×10^{-4} – 3.5×10^{-3}
Riihimäki et al. (2011)	CaCO ₃	实验室换热器	15	0–84 h	-5.9×10^{-2} – 2.3×10^{-1}

2.7 经济模型

我们定义了一个无量纲成本模型来量化准确预测 $R_f(t)$ 的实际价值。所有成本由清洗成本 C_{clean} 归一化。清洗策略包括固定周期清洗（每T/3或T/4天）、PINN预测驱动清洗和Oracle理论下界。无量纲成本比定义为实际策略总成本与Oracle总成本的比值。

3. 结果

3.1 预训练收敛

多机理合成数据预训练在3,000个epoch内收敛。数据损失从约 5×10^{-7} 降至 3×10^{-7} ，物理损失保持在约 2.7×10^{-10} 。

3.2 稀疏微调性能（N=15）

18条曲线的单seed（seed=42）结果显示：

- **纯物理拟合失败**：ODE-fit在15/18条曲线上失败（ $R^2 \approx 0$ 或负值）
- **PINN填补缺口**：这15条失败案例中12条达到 $R^2 > 0.90$
- **预训练消融**：NoPT+Phys在Source 001上 R^2 从0.93暴跌至-7.65
- **MLP/LSTM全面失败**：稀疏数据下最佳 $R^2 = 0.87$ ，中位数 R^2 低于 -10^3

3.3 代表性预测曲线

图3展示了四种不同类型结垢曲线在 $N = 15$ 下的预测对比。PINN准确捕捉了磷酸结垢的渐近饱和特征、合理跟踪了原油工业数据的噪声趋势、在 CaCO_3 涂层曲线上实现了近乎完美的预测。

3.4 外推：PINN vs. 随机森林

PINN在所有曲线和稀疏度水平上一致优于RF。优势在 $N = 5$ 时最大 ($\Delta R^2 = +1.3$ 至 $+18.7$)。

3.5 消融分析

预训练（而非微调阶段的物理损失）是PINN性能的主要驱动因素。PT+Phys $\approx$ PT+NoPhys 在几乎所有条件下成立。

3.6 单机理 vs. 多机理预训练 —— 论文核心发现

曲线类别	KS-only R^2	多机型 R^2	赢家
Source 001—磷酸（域内）	-1329	0.94	多机理
Source 002—原油（域外1）	0.21/−0.21	0.64/0.27	多机理
Source 003 未改性（域外2）	0.83–0.92	0.55–0.78	KS-only
涂层/表面/图案曲线（12条）	0.80–0.997	0.82–0.998	平局

核心发现——多样性防止过拟合：KS-only预训练达到 1.2×10^{-12} 的训练损失（几乎完美记忆200条KS轨迹），但这种极端过拟合导致灾难性脆弱——在其"主场"（Source 001，KS型渐近曲线）上达到 $R^2 = -1329$ 。多机理预训练通过强制网络同时满足五种不同的ODE约束来避免这种失败。物理损失无法降至零（在 3.1×10^{-7} 处平台化），但这个"失败"恰恰是重点：不可约的训练损失证明模型学到了一个**折衷表征**，能够在所有机理间良好工作。

3.7 经济分析

PINN驱动的计算策略一致实现最低成本比。最显著的优势出现在工业原油曲线上：固定周期策略成本比为1.0–2.8，PINN策略将成本降低93%–95%。

3.8 多seed统计验证

10-seed实验（种子100–109）确认Source 001的单seed结果 ($R^2 = 0.93$) 是异常值；10种子均值为 $R^2 = -2.14 \pm 8.90$ 。PINN在涂层/表面曲线上高度稳定 ($CV < 1\%$)。Source 001的极端方差 ($CV=416\%$) 由"先验不匹配"假说解释。5-seed $\times$ 18-curve补充实验（种子200–204）确认PINN平均

R^2 在12/18条曲线上超过0.90，Source 001恰好落在好区域 ($R^2 = 0.945 \pm 0.011$)，与10-seed实验中观察到的极端变异性一致。

4. 讨论

4.1 为什么预训练有效——以及为什么多样性至关重要

多机理预训练的有效性可以从两个互补的视角理解。

迁移学习视角：PINN在预训练期间学习结垢曲线动力学的共享表征，捕捉通用属性——单调性、渐近饱和、诱导延迟——这些属性无论具体控制物理如何都能迁移到未见过的真实曲线。

多样性防止过拟合视角：单机理消融揭示了一个更深层的机制。KS-only预训练通过对200条KS轨迹的函数形式过拟合达到近乎零的训练损失，但在接触真实数据（即使是KS型的Source 001）时灾难性崩溃。多机理预训练通过强制网络同时满足五种互不兼容的ODE约束来防止这种过度专业化。这个发现与多任务学习和领域泛化的观察一致——在多样化任务上训练产生的表征比任何单一任务上的训练都具有更好的迁移性能。

单机理预训练在何时足够？ Table 4揭示了一个细微差别：KS-only预训练在三条曲线上优于多机理——Source 003 Run1、Run2和Run3（未改性 CaCO_3 ， $R^2 = 0.83\text{--}0.92$ vs. $0.55\text{--}0.78$ ）。这是数据集中最嘈杂的曲线，重复实验间的变异性很高。我们提出假说：对这种曲线，更简单的Kern-Seaton先验在数据极度有限的情况下充当了**更强的正则化器**。多机理先验虽然更丰富但也更灵活，在数据既稀疏又嘈杂时可能将噪声误解为信号。

这表明预训练多样性与目标曲线复杂度之间存在**U型关系**：多样性太低导致过度专业化（Source 001，KS-only失败 $R^2 = -1329$ ）；灵活性太高在数据极度稀疏且嘈杂时可能允许噪声过拟合（Source 003未改性）；中等多样性水平为大多数曲线提供最佳正则化。实际启示：**对工业部署，多机理预训练是更安全的默认选择，但对于噪声极高且底层动力学简单特定曲线类型，更简单的预训练分布可能更可取。**

4.2 为什么直接ODE拟合失败——PINN如何弥补

15/18条曲线ODE拟合失败的根本原因是：三参数模型在仅有5–15个噪声数据点时是欠定的。优化器收敛到拟合训练点但泛化极差的参数。PINN通过提供**学习到的先验**而非更准确的ODE来规避这一失败。3,000个epoch的多机理预训练将物理上合理的 $R_f(t)$ 轨迹的丰富分布编码到网络权重中。

4.3 干净渐近曲线上的先验不匹配

Source 001（磷酸）呈现出一个有趣的反例：PINN展现出最高的跨种子方差（ $CV=416\%$ ）。我们提出假设存在先验不匹配效应：多机理预训练编码了五种不同ODE模型族的平均形状先验，这对复杂曲线提供了强正则化，但对最简单的渐近曲线产生了轻微的不匹配。这与迁移学习文献一致——当目标域偏离源域均值时，预训练模型提供最大的收益。

4.4 局限性与未来工作

(1) 绝对外推仍然困难——外推区域的 R^2 对任何方法都保持负值。(2) 原油曲线 ($R^2 = 0.58-0.62$) 反映了真实的工业复杂性。(3) PINN拥有13,249个参数但仅用5–30个数据点微调——这是良性过参数化的例子，预训练提供了强隐式正则化。(4) 诱导模型的sigmoid平滑参数 $\alpha = 10$ 在 $[5, 20]$ 范围内不敏感。

5. 结论

1. **多机理预训练至关重要，其价值在于多样性而非覆盖面。** 单机理预训练灾难性过拟合 ($R^2 = -1329$)，而多机理预训练在相同曲线上达到 $R^2 = 0.94$ 。五种训练ODE的多样性迫使网络学习鲁棒、可泛化的表征。
2. **框架在复杂结垢曲线上实现实用精度。** 5-seed多seed验证 ($N = 15$, 种子200–204) 确认PINN平均 R^2 在18条曲线中的12条上超过0.90。10-seed补充实验 (种子100–109) 揭示了Source 001的极端种子间变异性 ($CV=416\%$)，归因于多机理预训练与该干净渐近曲线之间的先验不匹配。
3. **物理约束预训练实现了外推能力。** 预训练后的PINN在外推任务中一致优于RF ($\Delta R^2 = +1.3$ 至 $+18.7$, $N = 5$)。
4. **该方法可立即工业部署。** 预训练仅需公开物理模型；微调每台换热器约3秒 (NVIDIA RTX 4060 GPU)；PINN驱动的清洗策略将无量纲成本降低20%–97%。

代码与数据可用性

所有代码、数据和预训练模型权重将在论文接收后以MIT许可证公开发布。匿名审稿期间的代码仓库链接可按要求提供。

GitHub: <https://github.com/wy2627962897/fouling-pinn-pretrain>

致谢

[待导师确认后填写]

中文版本仅供作者阅读参考，以英文LaTeX原稿为准。